

Дополнительное задание 2.1

Регуляризация - это техника, используемая для предотвращения переобучения модели на обучающих данных, которая призвана бороться с гигантскими весами, делая модель не такой извилистой, а веса меньше по модулю. Существует два типа регуляризации:


Регуляризация

L1

Lasso

(Лассо
регрессия)

$$\|y - Xw\|_2^2 + \lambda \|w\|_1 \rightarrow \min$$

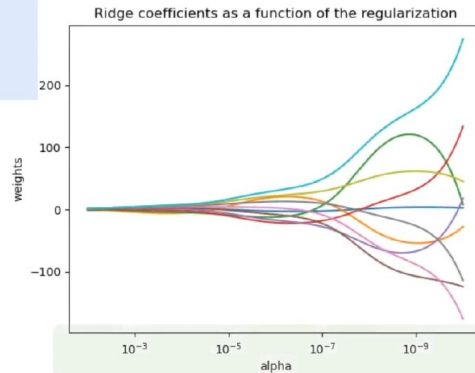


Основной плюс L1 регуляризации - это способность создавать разреженные модели, т.е. модели, где только небольшое количество признаков имеет ненулевые веса. Все это полезно в ситуациях, где признаков много, но только некоторые из них важны для прогнозирования.

Регуляризация Тихонова

Ridge (гребневая регрессия)

$$\|y - Xw\|_2^2 + \lambda \|w\|_2^2 \rightarrow \min$$



В отличие от L1 регуляризации, L2 не склонна обнулять веса. Вместо этого она уменьшает веса постепенно, делая модель более "гладкой" и менее подверженной влиянию шума в данных. L2 регуляризация полезна в ситуациях, когда количество признаков в данных велико или когда они сильно коррелированы.

А также их объединение:

Регуляризация L1 + L2

Elastic Net (Эластичная сеть)

$$\|y - Xw\|_2^2 + \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2 \rightarrow \min$$

Elastic Net комбинирует преимущества L1 и L2 регуляризации. Требуется настройка двух гиперпараметров (для L1 и L2 частей регуляризации), что может усложнить поиск оптимальных параметров.

Реализация:

```
def SGD(X, y, a0, b0, c0, learning_rate, cnt_max_iterations, batch_size, learning_rate_scheduling, regularization=None, lambda_0=0.1, alpha=0.5):
    coeffs = np.array([a0, b0])
    c = c0

    for i in range(cnt_max_iterations):

        # создаем массив данных размером batch_size
        # простыми словами: случайным образом сгенерировали батч точек, которые собираемся рассматривать
        indexes = np.random.randint(0, len(X) - 1, batch_size)

        # реальные данные (аргументы, реальные значения от этих аргументов)
        X_batch = X[indexes]
        y_batch = y[indexes]

        # считаем значение для текущих коэффициентов
        y_exec = np.dot(X_batch, coeffs) + c

        # используем среднеквадратичную функцию потерь
        # (производные у квадратичной функции потерь) -> чтобы получить градиент
        # расчет градиентов вектора и свободного скалара
        coeffs_grad = -2 * np.dot(X_batch.T, y_batch - y_exec) / batch_size # 2* batch_size (...) - batch_size
        # np.sum так как по факту скалярное умножение (1,...,1) * error
        c_grad = -2 * np.sum(y_batch - y_exec) / batch_size
```

↑
Параметр регуляризации L1 и L2

↖
Процент использования L1 регуляризации относительно Elastic регуляризации

```
if regularization == 'L1':
    coeffs_grad += lambda_ * np.sign(coeffs)
elif regularization == 'L2':
    coeffs_grad += lambda_ * coeffs
elif regularization == 'Elastic':
    coeffs_grad += alpha * lambda_ * np.sign(coeffs) + (1 - alpha) * lambda_ * coeffs

# идем дальше антиградиента
coeffs -= learning_rate * coeffs_grad
c -= learning_rate * c_grad

# меняем шаг
if learning_rate_scheduling == 'exponential':
    learning_rate *= 0.999
elif learning_rate_scheduling == 'stepwise':
    if i % 200 == 0:
        learning_rate *= 0.8

return coeffs, c
```

$$\|y - Xw\|_2^2 + \lambda \|w\|_1 \rightarrow \min$$

$$\|w\|_1 = |w_1| + |w_2| + \dots + |w_n|$$

$$\|y - Xw\|_2^2 + \lambda \|w\|_2^2 \rightarrow \min$$

$$\|a\|^2 = a_1^2 + a_2^2 + \dots + a_n^2$$

Проведённые испытания:
 Входные данные: $y = ax_1^2 + bx_2^2 + c$, где $a = 3, b = 8, c = 50$; $\lambda_1 = 3, \lambda_2 = 0.000001, \alpha = 0.5$.

Результаты:

batch_size	start	learning_rate_scheduling	start	regularization	method	polinom_info	a_diff	b_diff	c_diff	count_function_operations	work_time (ms)	memory (bytes)	learning_and_test_diff:
1	1			None		[2, 2]	0.064769	0.063486	0.269013	10000	176.332172	7882	0.132096
1	1			L1		[2, 2]	0.035213	0.052340	0.295259	10000	255.471706	5220	0.116296
2	1			L2		[2, 2]	0.061698	0.019534	0.319000	10000	198.287725	5080	0.108670
1	1			Elastic		[2, 2]	0.022435	0.002795	0.399055	10000	165.720051	4590	0.143541
4	1			None		[2, 2]	0.117857	0.186460	0.010321	10000	207.149020	4024	0.259934
5	1			L1		[2, 2]	0.003181	0.007951	0.030333	10000	171.316882	4204	0.192409
6	1			L2		[2, 2]	0.056801	0.036644	0.000381	10000	166.699686	4548	0.144413
7	1			Elastic		[2, 2]	0.013523	0.050322	0.195095	10000	166.720180	4540	0.208542
8	1			stepwise		[2, 2]	0.121010	0.168056	0.580119	10000	180.024147	4340	0.435188
9	1			stepwise		[2, 2]	0.082772	0.071895	0.453577	10000	178.383827	5092	0.416543
10	1			stepwise		[2, 2]	0.110872	0.160800	0.532714	10000	177.626555	4468	0.424052
11	1			stepwise		[2, 2]	0.080809	0.116248	0.448423	10000	179.113626	4156	0.359718
12	300			None		[2, 2]	0.021701	0.019238	0.315878	3000000	170.766115	22352	0.091577
13	300			L1		[2, 2]	0.023999	0.012340	0.320277	3000000	172.208024	22400	0.091241
14	300			L2		[2, 2]	0.024321	0.020388	0.324657	3000000	164.613512	22880	0.091876
15	300			Elastic		[2, 2]	0.020919	0.020208	0.323713	3000000	166.602059	22384	0.090739
16	300			None		[2, 2]	0.070164	0.070895	0.066547	3000000	167.701805	22668	0.179234
17	300			L1		[2, 2]	0.071161	0.067508	0.071358	3000000	169.302464	22736	0.181438
18	300			L2		[2, 2]	0.069192	0.069274	0.064768	3000000	169.912577	22832	0.178538
19	300			Elastic		[2, 2]	0.066976	0.067481	0.064046	3000000	167.124087	22720	0.170408
20	300			stepwise		[2, 2]	0.121942	0.124927	0.559322	3000000	174.454439	22680	0.400312
21	300			stepwise		[2, 2]	0.128096	0.126988	0.563096	3000000	179.147243	23168	0.418755
22	300			stepwise		[2, 2]	0.129939	0.120841	0.559076	3000000	180.055443	23192	0.408185
23	300			stepwise		[2, 2]	0.130305	0.130021	0.562062	3000000	180.030306	22604	0.413327
24	500			None		[2, 2]	0.024901	0.019674	0.320196	5000000	176.180001	35152	0.091493
25	500			L1		[2, 2]	0.024659	0.020817	0.321915	5000000	177.058935	34248	0.091402
26	500			L2		[2, 2]	0.024830	0.018735	0.320479	5000000	176.646365	35152	0.091333
27	500			Elastic		[2, 2]	0.025111	0.018849	0.320953	5000000	175.292253	34276	0.091121
28	500			None		[2, 2]	0.069147	0.068563	0.066917	5000000	170.295630	34616	0.178538
29	500			L1		[2, 2]	0.068596	0.068489	0.061359	5000000	177.064320	34668	0.177219
30	500			L2		[2, 2]	0.067733	0.068517	0.061272	5000000	167.706889	34616	0.177240
31	500			Elastic		[2, 2]	0.068557	0.067800	0.067955	5000000	170.588917	35120	0.172436
32	500			stepwise		[2, 2]	0.118381	0.111089	0.596243	5000000	179.520713	34168	0.411269
33	500			stepwise		[2, 2]	0.112043	0.130343	0.569388	5000000	173.945723	34272	0.414536
34	500			stepwise		[2, 2]	0.128839	0.128271	0.561848	5000000	181.626081	34504	0.409149
35	500			stepwise		[2, 2]	0.128853	0.130002	0.562854	5000000	178.006549	34036	0.410174
36	1000			None		[2, 2]	0.024902	0.020171	0.321017	10000000	184.890176	64244	0.091160
37	1000			L1		[2, 2]	0.021035	0.019207	0.319337	10000000	179.212089	64572	0.091236
38	1000			L2		[2, 2]	0.020639	0.020553	0.322547	10000000	180.387083	65096	0.091724
39	1000			Elastic		[2, 2]	0.020492	0.019391	0.321073	10000000	177.725572	64564	0.091257
40	1000			None		[2, 2]	0.069069	0.068056	0.066622	10000000	180.360079	64800	0.179143
41	1000			L1		[2, 2]	0.069218	0.068244	0.065431	10000000	182.488203	64300	0.178094
42	1000			L2		[2, 2]	0.067677	0.067304	0.067295	10000000	182.532654	64656	0.179250
43	1000			Elastic		[2, 2]	0.070222	0.068179	0.067814	10000000	179.391146	64300	0.179567
44	1000			stepwise		[2, 2]	0.128243	0.128798	0.566217	10000000	185.571671	64160	0.412127
45	1000			stepwise		[2, 2]	0.126579	0.130805	0.568215	10000000	188.684894	65128	0.413136
46	1000			stepwise		[2, 2]	0.127058	0.124370	0.562088	10000000	159.115017	63976	0.410152
47	1000			stepwise		[2, 2]	0.129804	0.129546	0.566007	10000000	183.272276	64080	0.412514